



حل عددی معادلات دیفرانسیل با مشتقات جزئی با ضرایب نامعین به کمک شبکه عصبی

پایان نامه کارشناسی ارشد ریاضیات کاربردی - آنالیز عددی

ساجد زرین پور نشرودکلی

استاد راهنما: دکتر خدیجه ندائی اصل

استاد مشاور: دکتر پروین رزاقی

دی ۱۳۹۹

چکیده

برای مدل سازی پدیده های واقعی با معادلات دیفرانسیل با مشتقات جزئی که شامل عدم قطعیت است، یکی از مشکلات وجود مجموعه ای از پدیده ها است که به عنوان مشکلات ابعاد بالا شناخته می شوند. خوشبختانه، اغلب تغییرات متغیرهای مدل می توانند توسط تعداد کمی خصوصیات دامنه توسط روش های کاهش مدل، ثبت شوند. برای مثال، می توان با استفاده از روش های مبتنی بر شبکه های عصبی متغیرهای مورد نظر را به عنوان تابعی از ضرایب ورودی اندازه گیری کرد. در این صورت، نمایش پذیری متغیرها توسط چنین شبکه ای را می توان با دید شبکه عصبی به عنوان یک تحول زمانی برای پیدا کردن جواب های مدل توجیه کرد. در این پایان نامه، ما یک روش میانبر برای پیدا کردن جواب های مدل روی دو معادله دیفرانسیل با مشتقات جزئی معروف در فیزیک و مهندسی را بازبینی مینمائیم. همچنین، ما به سراغ بررسی یک روش عددی سنتی از نظر تئوری خواهیم رفت و از این طریق، احتمالات جدیدی برای استفاده از شبکه های عصبی در حل معادلات دیفرانسیل را مطرح خواهیم نمود.

واژه های کلیدی: شبکه های عصبی، روش تفاضلات متناهی، روش المان های متناهی، معادلات دیفرانسیل با مشتقات جزئی، عدم قطعیت.

فهرست

دو	چکیده
۱	مقدمه
۲	انگیزه و هدف
۵	مقدارسنجی عدم قطعیت
۶	تعریف مسئله
۱۰	شبکه‌های عصبی
۱۲	روش پیشنهادی
۱۴	نتایج
۱۶	نتیجه‌گیری و کارهای پیش‌رو
۱۷	واژه‌نامه فارسی به انگلیسی

مقدمه

مقدارسنجی عدم قطعیت (۱۵) در فیزیک و مهندسی اغلب شامل مطالعه معادلات دیفرانسیل با مشتقات جزئی با میدان ضرایب تصادفی است. برای درک رفتار یک سیستم شامل عدم قطعیت، می‌توان کمیت‌های فیزیکی مشتق شده از معادلات دیفرانسیل توصیف کننده آن سیستم را به عنوان توابعی از میدان ضرایب استخراج کرد. اما حتی با گسسته‌سازی مناسب روی دامنه معادله و برد متغیرهای تصادفی، این کار به طور ضمنی به حل عددی معادله دیفرانسیل با مشتق جزئی به تعداد نمایی می‌انجامد.

یکی از روش‌های متداول برای مقدار سنجی عدم قطعیت، روش نمونه برداری مونته کارلو است. گرچه این روش در بسیاری از موارد کاربردی است اما کمیت اندازه‌گیری شده ذاتاً دارای نویز است. به علاوه، این روش قادر به پیدا کردن جواب‌های جدید در صورتی که قبلاً نمونه‌گیری نشده باشند، نیست. ما به دنبال یافت روشی هستیم که نویز داده‌ها در جواب آن تأثیر چندانی نداشته باشند و همچنین، قادر به ارائه جواب برای حالاتی که قبلاً نمونه‌گیری نشده باشند نیز باشد.

روش گالرکین تصادفی با استفاده چند جمله‌ای‌های آشوب یک جواب تصادفی را روی فضای متغیرهای تصادفی بسط می‌دهد و به این طریق مسئله با بعد بالا را به تعدادی معادله دیفرانسیل با مشتقات جزئی معین تبدیل می‌کند. این گونه روش‌ها به دقت زیادی درباره تعیین توزیع عدم قطعیت نیازمند هستند و از آن‌جا که پایه‌های استفاده شده مستقل از مسئله هستند، وقتی بعد متغیرهای تصادفی بالا باشد هزینه محاسباتی بسیار زیاد خواهد شد. ما به دنبال یافتن راهی برای حذف نیاز به محاسبه این پایه‌ها به صورت سنتی هستیم. یکی از اهداف این پایان‌نامه مطالعه نقطه ضعف روش‌های عددی سنتی همانند روش گالرکین تصادفی و روش المان‌های متناهی است. برای این منظور، تئوری روش المان‌های متناهی را مورد مطالعه دقیق‌تر قرار می‌دهیم.

هدف کار ما پارامتری کردن جواب یک معادله دیفرانسیل معین به کمک شبکه‌های عصبی (ساخت نمایشی دیگر برای جواب بر پایه ترکیب توابع) و سپس استفاده از روش‌های بهینه‌سازی برای یافتن

جواب معادله است. در این پایان نامه تابع مورد نظر برای پارامتری سازی روی میدان ضرایب معادله دیفرانسیل با مشتقات جزئی تعریف شده است. در واقع ما به دنبال کاهش بعد مبتنی بر نمایش شبکه عصبی برای حل معادلات دیفرانسیل با مشتقات جزئی همراه با عدم قطعیت هستیم.

انگیزه و هدف

مدل سازی طبیعت همیشه با پارامترهایی همراه است که مقادیر آنها از کنترل ما خارج است. اما عموماً ما درباره محدوده تغییرات این پارامترها اطلاعاتی داریم. به معادلاتی که شامل این گونه پارامترها هستند، معادلات با ضرایب عدم قطعیت گوییم. به طور مثال، در مورد حرکت نفت در سفره های زیر زمینی؛ برای بیان شیوه حرکت مایعات نیاز به دانستن مکان حفره ها در بافت سفره زیر زمینی داریم. این امر را می توان به صورت رسانایی مؤثر در حضور ناخالصی نیز در نظر گرفت. به عنوان مثالی دیگر، مسئله ای را مطرح می کنیم که نقطه شروع این رساله بوده است.

برای تشخیص سرطان پستان روش های متعددی موجود است. از جمله آن ها می توان به تصویر برداری پستان با بازتابش اشعه ایکس (XRM)^۱، تصویر برداری با استفاده از ارتعاشات مغناطیسی (MRI)^۲، تصویر برداری فراصوت (US)^۳، توموسنتز دیجیتال (DBT)^۴، ماموگرافی انتشار پوزیترون (PET)^۵ و توموگرافی فراصوت (UST)^۶ اشاره کرد. هر کدام از این روش ها اطلاعات را به طرق مختلفی نمایش می دهند، به این معنا که غده ای که در یکی از این روش ها غیر قابل تشخیص است در روش دیگر قابل تشخیص است؛ غده ای که در یک روش بافت مشکوک معرفی می شود، در روش دیگر می تواند به عنوان غده ای سالم و طبیعی معرفی شود. و این موضوع باعث ایجاد مشکلات بسیاری در روند تشخیص

¹ Projection X-ray mammography

² Magnetic resonance imaging

³ Ultra sound

⁴ Digital breast tomosynthesis

⁵ Positron emission mammography

⁶ Ultra sound tomography

و برنامه ریزی درمان می‌شود. در این مرحله، راه‌حلی که به ذهن می‌رسد، ترکیب نتایج حاصل از این روش‌ها برای بالابردن ضریب دقت است؛ لیکن مشکل دیگری مانع این کار می‌شود. بافت پستان بسیار کشسان است و به راحتی تغییر فرم می‌دهد. از طرفی در هرکدام از این روش‌ها بیمار به حالت خاصی قرار می‌گیرد که با روش دیگر متفاوت است. به طور مثال، طی MRI بیمار در حالت دمر قرار دارد ولی برای تصویربرداری فراصوت بیمار به پشت می‌خوابد. علاوه‌براین، در روش بایوپسی راهنمایی شده توسط MRI^۱ بافت پستان توسط صفحه‌های سخت و غیرقابل انعطافی بی حرکت می‌شوند که منجر به فشرده شدن بافت نیز می‌شود. بنابراین، شکل، اندازه و مکان غده در این تصاویر متفاوت خواهد بود. این امر مقایسه تصاویر را با سختی بسیار همراه می‌کند. علاوه‌براین، برای برنامه‌ریزی پیش از جراحی، پزشک نیاز به دانستن مکان و اندازه دقیق غده دارد. بنابراین، نیاز به توسعه الگوریتم‌های ثبت غیرسخت^۲ احساس می‌شود.

روش‌هایی مبتنی بر روش المان‌های متناهی^۳ برای حل این مسئله ارائه شده‌اند. اما مشکل عمده این روش‌ها هزینه محاسباتی بالای آنها است. مطابق آنچه در (۷) گفته شده است، به طور متوسط اجرای یک شبیه‌سازی صد و بیست دقیقه به طول می‌انجامد که برای مصارف کلینیکی مقرون به صرفه نیست. مارتینز و همکارانش (۷) در سدد ارائه روشی برای کاهش این هزینه محاسباتی با استفاده از شبکه‌های عصبی بودند. گرچه، مدل ارائه شده توسط آنها زمان محاسبات را به طرز چشمگیری کاهش می‌دهد، اما پارامترهای مدل مورد مطالعه آنها ثابت است. به عبارت دیگر، با توجه به این‌که این پارامترها از بدنی به بدن دیگر متفاوت هستند، برای ارائه یک مدل مختص به بیمار در زمانی قابل قبول، نیاز به توسعه مدل برای فراگیری پارامترهای دارای عدم قطعیت است. به طور مثال، نیازمند در نظر گرفتن ضریب کشسانی بدن بیمار، که یک ضریب عدم قطعیت است، هستیم. از این رو، برآن شدیم که بدنبال حل عددی معادلات دیفرانسیل (بیضوی) به کمک شبکه‌های عصبی باشیم.

در روش‌های عددی متدوال، هدف یافتن تقریبی از جواب مدل در یک فضای متناهی یا غیر متناهی

¹ MRI-guided biopsy

² Non-rigid registration algorithm

³ Finite element method

است که به صورت یک ترکیب خطی از پایه های آن فضا در نقاط رأسی بدست می آید. دقت این تقریب با تعداد نقاط رأسی به کار رفته رابطه مستقیم دارد. بنابراین، محاسبه تقریبی دقیق برای مسائل پیچیده روی دامنه های پیچیده، همچون محاسبه میزان تغییر فرم بافت پستان در اثر نیروهای وارده، به ناچار مستلزم استفاده از تعداد بسیار زیادی نقاط رأسی روی دامنه مدل می باشد که به طور مستقیم منجر به افزایش زمان محاسبه جواب مدل می شود. از این رو با تکیه بر اصول شبکه های عصبی بدنبال راهی برای حذف نیاز به محاسبه مستقیم پایه های فضای تقریب روی نقاط رأسی با استفاده از روشی مبتنی بر کاهش بعد فضای جواب با حفظ خصوصیات اصلی مورد نیاز خود از جواب هستیم. با توجه به اینکه نمایش جواب بدست آمده از شبکه های عصبی به صورت ترکیبی متناهی از توابع است، می توانیم با تعویض نمایش جواب از حالت خطی (روش های عددی متداول) با حالت غیر خطی (نمایش شبکه های عصبی) به این مهم دست یابیم. ایده، استفاده از شبکه های عصبی برای یادگیری نگاشتی از دامنه ضرایب عدم قطعیت به فضای جواب بر اساس مجموعه داده از قبل محاسبه شده است. به این ترتیب می توان گفت روشی که ما در صدد گزارش آن هستیم، یک روش کاهش بعد برای محاسبه جواب بدون نیاز به حل مستقیم معادله دیفرانسیل است. در این رساله، معادلات دیفرانسیل با مشتقات جزئی بیضوی خطی و غیر خطی ناهمگن را مورد بررسی قرار می دهیم. نکته حائز اهمیت این است که از آن جا که این روش، یک روش مبتنی بر داده است، نوع مدل (بیضوی، هذلولوی و یا سهموی) یا روش عددی استفاده شده برای نمونه گیری جواب و ایجاد پایگاه داده جدید، در آن تغییر چشمگیری ایجاد نمی نمایند. بنابراین، این روش برای هر سه نوع معادلات دیفرانسیل با مشتقات جزئی در هر دو حالت همگن و ناهمگن قابل استفاده است. از طرف دیگر، از آنجا که ما از محاسبات تنسوری در لایه های این شبکه بهره می بریم، این مدل با کمترین میزان تغییرات قابل استفاده در ابعاد بالاتر نیز است. برای نمایش این ادعا، معادله اول را در یک بعد و معادله دوم را در دو بعد بررسی خواهیم کرد.

مقدارسنجی عدم قطعیت

مقدارسنجی عدم قطعیت مطالعه اعتمادپذیری نتیجه‌گیری علمی است. به عبارت دیگر به جای مطالعه درستی هر فرضیه به طور جزئی، به دنبال مطالعه ارتباط بین فرضیات هستیم. سؤال اساسی در مسائل مقدارسنجی عدم قطعیت این است که با فرض اینکه اطلاعاتی درمورد خطا در ورودی‌های مدل در دسترس باشد، در مورد تغییرات در خروجی چه می‌توان گفت؟ (۱۵) برای مقدارسنجی عدم قطعیت یک کمیت فیزیکی، یکی از راه‌ها پیدا کردن نگاهی از فضای پارامترهای عدم قطعی در ورودی مدل به فضای خروجی مدل است. خوشبختانه این نگاشت‌ها عموماً وابسته به تعداد محدودی 'خصیصه' هستند که می‌توان آنها را با تعداد محدودی نمونه‌برداری و حل مدل دیفرانسیلی به‌دست آورد.

عموماً عدم قطعیت ناشی از فرضیات ساختار مدل و یا مقدار وردی‌های آن است. در این پایان‌نامه، ما روی عدم قطعیت حاصل از عدم قطعیت روی ورودی‌های مدل تمرکز خواهیم کرد. عدم قطعیت روی داده‌های ورودی به چهار دسته پارامترهای تصادفی، میدان‌های تصادفی، نویز سفید و همبسته طبقه‌بندی می‌شود (۱۶). در مسئله یافتن ضریب رسانایی مؤثر بر محیط ناهمگون عدم قطعیت روی داده‌های ورودی از نوع پارامترهای تصادفی و در مسئله تعیین سطح انرژی حالت پایه با پتانسیل زمینه ناهمگون از نوع نویز سفید هستند.

اغلب مقدار خروجی مورد نظر ما مقداری است که از فراوری داده‌های خروجی مدل اولیه حاصل می‌شود. در این‌جا نیز، هدف ما در واقع کنترل عدم قطعیت خروجی ثانویه مدل است که از فراوری حاصل می‌شود. با فرض اینکه عدم قطعیت ورودی مدل با بردار $a = (a_1, \dots, a_N)^T$ پارامتری شده باشد، جواب معادله علاوه بر ابعاد فضایی x و بعد زمان t به بردار پارامترهای رندوم a نیز وابسته است. بنابراین یک نمونه‌گیری از جواب می‌تواند به صورت $u(x, t; a)$ به ازای یک انتخاب مشخص از پارامترهای رندوم بیان شود. گرچه ما علاقه‌مند به بررسی هر کدام از این نمونه‌ها به طور مجزا نیستیم (۱۶). بنابراین ما پایگاه داده خود را بر همین اساس خواهیم ساخت. کنترل عدم قطعیت مقدار خروجی مطلوب معمولاً مستلزم تکامل یک انتگرال چندگانه روی بردار پارامتری a است (۱۶).

مدل مطرح شده در این پایان نامه، این تکامل و تقریب عددی جواب آن را به طور همزمان بر عهده دارد. بدین منظور، به جای تلاش برای یافتن جواب مدل، در سدد یافتن نگاشتی از پارامترهای تصادفی ورودی به خروجی پردازش شده مدل هستیم. دقت کنید که به همین دلیل، با اینکه ما روش خود را روی معادلات بیضوی بررسی کردیم، همین روش برای معادلات هذلولوی و سهموی نیز کاراست.

تعریف مسئله

در این پایان نامه، هدف ما بررسی یک مدل میانبر برای حل مسائل معادلات دیفرانسیل با مشتقات جزئی به کمک شبکه‌های عصبی است. به عبارت روشن‌تر یافتن نگاشتی از فضای عدم قطعیت مسئله به فضای جواب. مسائلی که در این رساله برای حل انتخاب شده اند از این جهت حائز اهمیت بوده‌اند که هر دو حالت خطی و غیر خطی، معادلات دیفرانسیل غیر همگن شامل عدم قطعیت را پوشش می‌دهند.

یافتن ضریب رسانایی مؤثر در محیط ناهمگون

معادله اول، رسانایی مؤثر در یک جهت انتخاب شده درون یک محیط غیر همگون را توسط ضریب رسانش توصیف می‌کند. محیط غیر همگون، محیطی است که در آن خصوصیات مورد توجه در تمامی نقاط یکسان نیستند. این امر ممکن است به دلایلی همچون جنس‌های گوناگون مواد تشکیل دهنده یا چگالی‌های متفاوت مربوط باشد. فرض ما بر آن است که ضریب رسانایی ماده در جهات متفاوت یکسان نباشد و این ضریب را با $a(x)$ نمایش می‌دهیم. این بردار از نمونه‌گیری توابعی به فرم زیر روی نقاط رأسی حاصل می‌شود:

$$\mathcal{A} = \{a \in L^\infty([0, 1]^d) | \lambda_1 \geq a(x) \geq \lambda_0 > 0\}, \quad (1)$$

که در آن λ و λ_1 اعداد ثابتی هستند. با فرض انتخاب یک جهت دلخواه ثابت $\xi \in \mathbb{R}^d$ ، میزان ضریب رسانش در آن جهت مطلوب است. به عبارت دقیق‌تر، جواب معادله زیر مد نظر است

$$A_{\text{eff}}(\mathbf{a}) = \min_{u(x)} \int_{[0,1]^d} \mathbf{a}(x) \|\nabla u(x) + \xi\|^2 dx.$$

این معادله با فرم دیفرانسیلی زیر هم‌ارز است. به عبارت دیگر، جواب مسئله بهینه‌سازی فوق در معادله دیفرانسل زیر صدق میکند و جواب معادله دیفرانسیل زیر نیز تابع هدف مسئله بهینه‌سازی فوق را بهینه می‌کند.

$$-\nabla \cdot (a(x)(\nabla u(x) + \xi)) = 0. \quad (2)$$

از این‌رو، با جای حل مسئله مینیم‌سازی، فرم مذکور را به کمک گسسته‌سازی زیر با گام $h = \frac{1}{n}$ حل می‌نماییم.

$$\begin{aligned} & -\sum_{k=1}^d \frac{a_{i+\frac{1}{\gamma}e_k} - a_{i-\frac{1}{\gamma}e_k}}{h} \cdot \frac{u_{i+e_k} - u_i}{h} - \sum_{k=1}^d a_{i-\frac{1}{\gamma}e_k} \frac{u_{i+e_k} - 2u_i + u_{i-e_k}}{h^2} - \sum_{k=1}^d \xi_k \frac{a_{i+\frac{1}{\gamma}e_k} - a_{i-\frac{1}{\gamma}e_k}}{h} \\ & = -\sum_{k=1}^d \frac{a_{i+\frac{1}{\gamma}e_k} u_{i+e_k} - a_{i+\frac{1}{\gamma}e_k} u_i - a_{i-\frac{1}{\gamma}e_k} u_{i+e_k} + a_{i-\frac{1}{\gamma}e_k} u_i + a_{i-\frac{1}{\gamma}e_k} u_{i+e_k} - 2a_{i-\frac{1}{\gamma}e_k} u_i + a_{i-\frac{1}{\gamma}e_k} u_{i-e_k}}{h^2} \\ & \quad - \sum_{k=1}^d \xi_k \frac{a_{i+\frac{1}{\gamma}e_k} - a_{i-\frac{1}{\gamma}e_k}}{h} \\ & = -\sum_{k=1}^d \frac{a_{i+\frac{1}{\gamma}e_k} [u_{i+e_k} - u_i] - a_{i-\frac{1}{\gamma}e_k} [u_i - u_{i-e_k}]}{h^2} - \sum_{k=1}^d \xi_k \frac{a_{i+\frac{1}{\gamma}e_k} - a_{i-\frac{1}{\gamma}e_k}}{h} \\ & = \sum_{k=1}^d \frac{-a_{i+\frac{1}{\gamma}e_k} u_{i+e_k} + [a_{i+\frac{1}{\gamma}e_k} + a_{i-\frac{1}{\gamma}e_k}] u_i - a_{i-\frac{1}{\gamma}e_k} u_{i-e_k}}{h^2} - \sum_{k=1}^d \xi_k \frac{a_{i+\frac{1}{\gamma}e_k} - a_{i-\frac{1}{\gamma}e_k}}{h} = 0. \end{aligned}$$

که می‌تواند به صورت $(L_a U)_i = (b_a)_i$ نمایش داده شود که در آن

$$(L_a u)_i := \sum_{k=1}^d \frac{-a_{i+\frac{1}{\tau}e_k} u_{i+e_k} + (a_{i-\frac{1}{\tau}e_k} + a_{i+\frac{1}{\tau}e_k}) u_i - a_{i-\frac{1}{\tau}e_k} u_{i-e_k}}{h^2} \quad (3)$$

$$(b_a)_i := \sum_{k=1}^d \frac{\xi_k (a_{i+\frac{1}{\tau}e_k} - a_{i-\frac{1}{\tau}e_k})}{h}. \quad (4)$$

همان‌طور که اشاره کردیم، قصد ما حل این مسئله در حالت یک بعدی است. بنابراین در روابط بالا $d = 1$ قرار می‌دهیم. با در نظر گرفتن شرط مرزی $u|_{\partial\Omega} = 0$ ، در مرحله بعد اقدام به نوشتن فرم ماتریسی آن می‌نماییم.

$$L_a = \frac{1}{h^2} \begin{bmatrix} a_{1-\frac{1}{\tau}e_1} + a_{1+\frac{1}{\tau}e_1} & -a_{1+\frac{1}{\tau}e_1} & & & \\ -a_{2-\frac{1}{\tau}e_1} & a_{2-\frac{1}{\tau}e_1} + a_{2+\frac{1}{\tau}e_1} & -a_{2+\frac{1}{\tau}e_1} & & \\ & \ddots & \ddots & \ddots & \\ & & -a_{n-1-\frac{1}{\tau}e_1} & a_{n-1-\frac{1}{\tau}e_1} + a_{n-1+\frac{1}{\tau}e_1} & -a_{n-1+\frac{1}{\tau}e_1} \\ & & & -a_{n-\frac{1}{\tau}e_1} & a_{n-\frac{1}{\tau}e_1} + a_{n+\frac{1}{\tau}e_1} \end{bmatrix}_{n \times n},$$

$$b_a = \frac{1}{h} \begin{bmatrix} \xi_1 (a_{1+\frac{1}{\tau}e_1} - a_{1-\frac{1}{\tau}e_1}) \\ \xi_1 (a_{2+\frac{1}{\tau}e_1} - a_{2-\frac{1}{\tau}e_1}) \\ \vdots \\ \xi_1 (a_{n+\frac{1}{\tau}e_1} - a_{n-\frac{1}{\tau}e_1}) \end{bmatrix}_{n \times 1}, \quad U = \begin{bmatrix} u_1 \\ u_2 \\ \vdots \\ u_n \end{bmatrix}_{n \times 1}.$$

با تعاریف بالا جواب را به صورت $L_a U = b_a$ می توان نوشت. اما برای رسیدن به گسسته سازی نهایی، هنوز نیاز داریم که مسئله را با در نظر گرفتن شرط مرزی دوره ای بازنویسی نماییم.

$$L_a^{\text{patched}} = \frac{1}{h^2} \begin{bmatrix} a_{1-\frac{1}{2}}e_1 + a_{1+\frac{1}{2}}e_1 & -a_{1+\frac{1}{2}}e_1 & & & -a_{1-\frac{1}{2}}e_1 \\ & \ddots & \ddots & \ddots & \\ & & & & \\ -a_{n+\frac{1}{2}}e_1 & & -a_{n-\frac{1}{2}}e_1 & a_{n-\frac{1}{2}}e_1 + a_{n+\frac{1}{2}}e_1 & \end{bmatrix}_{n \times n},$$

$$U = \begin{bmatrix} u_1 \\ u_2 \\ \vdots \\ u_n \end{bmatrix}_{n \times 1},$$

که در آن $a_{1-\frac{1}{2}}e_1 = \frac{a_n+a_1}{2}$ و $a_{n+\frac{1}{2}}e_1 = \frac{a_1+a_n}{2}$. نهایتاً پس از حل مسئله توسط یک روش تکراری با گسسته سازی مطرح شده، جواب بدست آمده را در رابطه زیر قرار می دهیم تا به رسانایی مؤثر دست یابیم

$$A_{\text{eff}}(a) = h^d (u_a^T L_a^{\text{patched}} u_a - 2 u_a^T b_a + a^T 1). \quad (5)$$

تعیین سطح انرژی حالت پایه با پتانسیل زمینه ناهمگون

معادله دوم، معادله غیرخطی شرودینگر دو بعدی است. هدف از این معادله، یافتن میزان انرژی حالت پایه الکترون با پتانسیل اولیه همراه با عدم قطعیت است. حالت پایه سطح انرژی ای است که الکترون مایل به اخذ آن در دمای صفر مطلق می باشد. این معادله به صورت یک مسئله مقدار ویژه به فرم زیر

تعریف می‌شود. هدف در حل این مسئله یافتن کوچکترین مقدار ویژه آن (حالت پایه) است

$$-\Delta u(x) + a(x)u(x) + \sigma u(x)^3 = E_\sigma u(x)$$

$$x \in [0, 1]^d, s.t. \int_{[0, 1]^d} u(x)^2 dx = 1.$$

مشابه آنچه در قسمت قبل آمد معادله فوق را گسسته می‌کنیم

$$(Lu)_i + a_i u_i + \sigma u_i^3 = E_\sigma u_i, \sum_{i=1}^{n^d} u_i^2 h^d = 1 \quad (6)$$

که در آن

$$(lu)_i := \sum_{k=1}^d \frac{-u_{i+e_k} + 2u_i - u_{i-e_k}}{h^2}.$$

شبکه‌های عصبی

شبکه عصبی^۱ از تعدادی واحد متصل به هم نام نورون^۲ تشکیل می‌شود. هر نورون دارای یک وضعیت داخلی است که در ترکیب با داده ورودی تغییر می‌کند و توسط تابع فعال‌سازی^۳ خروجی نورون را به حالت روشن یا خاموش تغییر می‌دهد. به عبارت ریاضی، هر نورون دارای اسکالرهایی داخلی به نام وزن^۴ و بایاس^۵ و تابع فعال‌سازی ای است که به ترتیب با W و b و ϕ نمایش داده می‌شوند. و خروجی نورون در این صورت با فرض اینکه X ورودی نورون باشد به صورت $\phi(WX + b)$ خواهد بود. برای این ساختار تابعی به عنوان تابع انحراف^۶ به عنوان تابع هدف تعریف می‌شود که در حالت یادگیری تحت

¹ Neural network

² Neuron

³ Activation function

⁴ Weight

⁵ Bias

⁶ Loss function

نظارت^۱ به عنوان معیاری برای تعیین انحراف جواب‌های شبکه از جواب‌های واقعی معرفی شده به شبکه است. در این صورت، می‌توان روند یادگیری یک شبکه عصبی را معادل با یک مسئله کمینه‌سازی برای کمینه کردن میزان این تابع هدف در نظر گرفت. ابزار شبکه برای کمینه سازی این تابع هدف، تغییر وزن‌ها و بایاس‌های نورون‌های خود است. قضیه زیر که به قضیه تقریب جهانی مشهور است، شرایط استفاده از شبکه‌های عصبی برای تقریب جواب مسئله را بیان می‌کند.

قضیه. (قضیه تقریب جهانی)

۱. (حالت نامتناهی) فرض کنید $\varphi : \mathbb{R} \rightarrow \mathbb{R}$ یک تابع غیرثابت پیوسته بی‌کران باشد که آن را تابع فعال‌سازی می‌نامیم. فرض کنید I_m بیان‌گر ابر مکعب m -بعدی $[0, 1]^m$ باشد، و فضای توابع پیوسته حقیقی مقدار روی I_m با $C(I_m)$ نمایش داده شود. در این صورت، به ازای هر $\varepsilon > 0$ دلخواه و هر تابع $f \in C(I_m)$ ، ثوابت حقیقی مانند $v_i, b_i \in \mathbb{R}$ و بردارهای $w_i \in \mathbb{R}^m$ برای $i = 1, \dots, N$ وجود دارند، به طوری که می‌توانیم

$$F(x) = \sum_{i=1}^N v_i \varphi(w_i^T x + b_i)$$

را به عنوان تقریبی از f ارائه دهیم:

$$|F(x) - f(x)| < \varepsilon$$

که در آن $x \in I_m$ است. به عبارت دیگر، توابع به شکل $F(x)$ در $C(I_m)$ چگال‌اند. این نتیجه به ازای هر زیر مجموعه فشرده دیگری از \mathbb{R}^m به جای I_m نیز برقرار است.

۲. (حالت کران‌دار) در شبکه‌های کران‌دار، برای هر تابع انتگرال‌پذیر لبگ مانند $f : \mathbb{R}^n \rightarrow \mathbb{R}$ و

¹ Supervised learning

هر $\epsilon > 0$ یک شبکه ReLU^۱ کامل \mathcal{A} با عرض $d_m \leq n + ۴$ به گونه ای موجود است که نمایش داده شده با این شبکه در رابطه

$$\int_{\mathbb{R}^n} |f(x) - F_{\mathcal{A}}(x)| dx < \epsilon$$

صدق نماید.

روش پیشنهادی

معادله تعیین ضریب رسانش مؤثر تنها در یک بعد، و معادله شرودینگر در دو بعد حل خواهند شد. هدف این انتخاب تأکید بر این نکته بوده است که با اندک تغییری در ساختار ورودی‌های شبکه، می‌توان از این مدل برای حل معادلات دیفرانسیل در هر بعد دلخواهی استفاده کرد. دلیل این امر نیز استفاده از محاسبات تنسوری در ساختار شبکه عصبی می‌باشد.

توجه خواننده را به این نکته جلب می‌نمائیم که روش عددی‌ای که برای ساخت پایگاه داده اولیه مورد نیاز برای شبکه عصبی استفاده می‌شود، از جهتی حائز اهمیت است؛ زیرا به میزانی که خطای ما روی داده اولیه کمتر باشد اطمینان ما از جواب شبکه عصبی بیشتر است. از طرفی، بررسی اینکه این خطا در داده‌های اولیه چگونه در شبکه عصبی منتشر می‌شود و شبکه تا چه میزان به خطا در داده‌های ورودی خود حساس است، از حیطه این پایان نامه خارج است. بنابراین، از آنجایی که شبکه عصبی صرفاً از یک جدول داده بهره می‌برد و نسبت به اینکه این جدول داده‌ای از چه راهی بدست آمده اطلاع قبلی ندارد، در این پایان نامه فرض بر این است که روش عددی استفاده شده برای ایجاد پایگاه داده با شبکه عصبی غیر مرتبط است و بنابراین از هر روش عددی‌ای می‌توان استفاده نمود. به همین منظور از روش تفاضلات متناهی برای تولید پایگاه داده در هر دو مسئله استفاده نموده‌ایم.

¹ Rectified linear unit

برای حل معادلات با روش تفاضلات متناهی، معادله تعیین ضریب رسانش مؤثر روی یک شبکه نه نقطه‌ای متساوی‌الفاصله، با مقادیر ضرایب عدم قطعیت با توزیع نرمال $\mathcal{U}[0.3, 1.5]$ ، و معادله شرودینگر غیر خطی روی یک شبکه هشتاد و یک نقطه‌ای متساوی‌الفاصله (گسسته سازی نه نقطه‌ای هر کدام از ابعاد) با مقادیر ضرایب عدم قطعیت با توزیع نرمال $\mathcal{U}[1, 16]$ به تعداد نمونه‌های مورد نیاز حل می‌شوند. سپس درصدی از تکرارها (در اینجا هفتاد و پنج درصد) به عنوان داده برای مرحله آموزش و الباقی برای مرحله آزمون کنار گذاشته می‌شوند.

شبکه عصبی متشکل از سه بخش است. بخش اول و سوم قرینه یکدیگر و متشکل از لایه‌های پیچشی^۱ هستند که به واسطه بخش دوم که یک استخر مجموع^۲ است به هم متصل شده‌اند. ورودی این شبکه برای رسانایی مؤثر یک بردار و برای معادله شرودینگر یک ماتریس است. دقت شود که در حالت دو بعدی، قبل از لایه‌های پیچشی، ابعاد داده ورودی گسترش می‌یابد. این امر با توجه به اینکه شرط مرزی مسئله دوره‌ای است، به صورت گسترش دوره‌ای انجام می‌شود. خروجی شبکه در هر دو حالت یک اسکالر است. که در مورد ضریب رسانائی مؤثر، این اسکالر برابر ضریب رسانائی مؤثر در جهت ثابت \hat{e} و در مورد معادله شرودینگر، برابر با سطح انرژی حالت پایه است.


شبکه پس از چندین بار مرور داده‌ها در انتها ضرایب خود را به گونه ای تنظیم می‌کند که تابع هدفی که به آن معرفی کرده‌ایم را کمینه نماید. وقتی تابع مذکور به میزان کمینه خود برسد می‌گوییم آموزش شبکه به اتمام رسیده است. از این پس می‌توانیم با خوراندن ورودی جدید به شبکه از آن برای یافتن جواب استفاده نماییم.

¹ convolutional layers

² sum-pooling


نتایج

مقادیر ضریب رسانایی مؤثر و انرژی حالت پایه به ترتیب 0.76800650 و $10/17474556$ بدست آمده اند که خطای L^2 به ترتیب، عبارت اند از $10^{-3} \times 102100$ و $10^{-5} \times 7235$. نمودار توزیع خطا بر حسب نمونه برای ضریب رسانایی مؤثر به شرح زیر است.



شکل ۱: خطای مرتکب شده روی مجموعه آزمون به تفکیک نمونه

همچنین، نمودار مشابه برای انرژی حالت پایه نیز به شرح زیر است. همان‌گونه که مشاهده می‌شود،



شکل ۲: خطای مرتکب شده روی مجموعه آزمون به تفکیک نمونه

تعداد نمونه‌های مورد استفاده قرا گرفته برای آموزش ماشین در معادله شرودینگر بسیار کمتر از معادله ضریب رسانایی مؤثر است. دلیل این امر هزینه بالای محاسباتی برای محاسبات این معادله نسبت به معادله اول بوده است. دقت کنید که در این معادله، به دلیل وجود جمله غیر خطی، مجبور به استفاده

از یک روش تکراری برای حل معادله هستیم. روش حل ما بر مبنای روش هموتویی نیوتنی بوده است. همچنین دقت شبکه عصبی در معادله شرودینگر به مراتب کمتر از معادله ضریب رسانایی مؤثر است. دلیل این امر را می‌توان به دو عامل نسبت داد. عامل اول تعداد کمتر نمونه‌هاست که به آن اشاره شد و دلیل دوم، بزرگ بودن برچسب‌ها و کوچک بودن مقیاس فواصل آن‌ها نسبت به اندازه خود برچسب‌ها. بهر روی، برای تعدیل این مشکل و بالا بردن دقت داده‌ها توسط روش نرمال‌سازی Z-Score نرمال شده‌اند.

نتیجه‌گیری و کارهای پیش‌رو

همان‌گونه که از نتایج مشهود است، شبکه‌های عصبی توانایی بالایی در تقریب روابط پنهان مابین داده‌ها دارند. همچنین سادگی روش، آن را به یک روش در دسترس تبدیل می‌کند. ضمن اینکه پس از طی مرحله آموزش، شبکه عصبی قادر است جواب مسئله را تقریباً به طور آنی ارائه کند. یکی از محدودیت‌های شبکه‌های عصبی در مورد اندازه مقیاس ورودی‌ها است. به این معنی که در صورتی که برچسب‌ها بسیار بزرگ باشند یا با فاصله بسیار از هم، روند یادگیری با مشکل مواجه می‌شود. همان‌گونه که مشاهده می‌شود خطا در معادله شرو دینگر به علت بزرگ بودن برچسب‌ها در مقایسه با ضرایب عدم قطعیت بیشتر است. ما از روش نرمال سازی Z-Score برای نرمال سازی استفاده نمودیم. در ادامه این پایان نامه، سؤالات زیر می‌تواند مورد بررسی بیشتر قرار گیرد

- چه روش‌های دیگری برای حل این مسئله موجود است؟
- آیا این نرمال سازی خود خطایی به مدل تحمیل می‌کند؟ کران این خطای تحمیلی چیست؟
- میزان حساسیت شبکه عصبی به خطا در داده‌های ورودی و همچنین الگوی انتشار خطا در آن به چه صورت است؟
- آیا این انتشار خطا با افزایش عمق شبکه و یا استفاده از ساختارهای متفاوت اعم از توابع متفاوت برای توابع فعال سازی و همچنین نوع آرایش نوروں‌ها ارتباطی دارد؟

واژه‌نامه فارسی به انگلیسی

convolutional neural-network	شبکه عصبی پیچشی
deep learning	یادگیری عمیق
finite difference method	روش تفاضلات متناهی
finite element method	روش عناصر متناهی
inhomogeneous media	محیط ناهمگن
neural-network	شبکه عصبی
spatial dimension	بعد فضائی
uncertainty	عدم قطعیت
uncertainty quantification	مقدار سنجی عدم قطعیت
nonlinear	غیر خطی
automatic differentiation	مشتق‌گیری اتوماتیک
graphic processor unit (GPU)	هسته پردازنده گرافیکی
feedforward neural network	شبکه رو به جلو
artificial neural network	شبکه عصبی مصنوعی
bias	بایاس
weight	وزن
activation function	تابع فعال‌سازی
loss function	تابع هزینه
neuron	نورون

پایگاه داده مستخرج از یک منبع dataset
 پایگاه داده مستخرج از منابع متفاوت data set
 بیش همسان سازی overfitting
 کم همسان سازی underfitting
 گشت در داده ها epoch
 دسته batch
 روش کاهش آشوبناک گرادیان stochastic gradient decent (SGD)